Десятое домашнее задание: строки, бор и Ахо-Корасик СПБ, Академический Университет, 22 апреля 2015

Содержание

Обязатель	ные задачи	2
Задача А.	Словарь [1 sec, 256 mb]	2
Задача В.	Поиск набора образцов [0.25 sec, 256 mb]	3
Задача С.	К-я строка [0.5 sec, 256 mb]	4
Задача D.	Prof. Жужжащий профессор [0.1 sec, 256 mb]	5
Бонус		6
Задача Е.	Подстроки-3 [0.25 sec, 256 mb]	6
Задача F.	Вирусы [0.5 sec, 256 mb]	7
Задача G .	Набор строк [3.5 sec, 256 mb]	8
Задача Н.	Под-бор [1 sec, 256 mb]	9

В некоторых задачах большой ввод и вывод. Имеет смысл пользоваться супер быстрым вводом-выводом:

http://acm.math.spbu.ru/~sk1/algo/input-output/fread_write.cpp.html

В некоторых задачах нужен STL, который активно использует динамическую память (set-ы, map-ы) переопределение стандартного аллокатора ускорит вашу программу: http://acm.math.spbu.ru/~sk1/algo/memory.cpp.html

Обязательные задачи

Задача А. Словарь [1 sec, 256 mb]

Пожалуйста, сдайте эту задачу без использования Ахо-Корасик!

Дан набор слов и текст, требуется определить для каждого слова, присутствует ли оно в тексте как подстрока.

Формат входных данных

В первой строке дан текст (не более 10^6 строчных латинских букв). Далее дано число M — количество слов в словаре.

В следующих M строках записаны слова (не более 30 строчных латинских букв). Слова различны и отсортированы в лексикографическом порядке.

Суммарная длина слов в словаре не более 10^5 .

Формат выходных данных

M строк вида Yes, если слово присутствует, и No иначе.

dictionary.in	dictionary.out
trololo	No
3	Yes
abacabadabacaba	Yes
olo	
trol	

Задача В. Поиск набора образцов [0.25 sec, 256 mb]

Напишите программу, которая для каждой строки из заданного набора S проверяет, верно ли, что она содержит как подстроку одну из строк из набора T.

Формат входных данных

Первая строка входного файла содержит натуральное число n — количество строк в наборе T ($n \leq 1000$). Каждая из следующих n строк содержит непустую строку длины не более 80-ти символов.

Оставшаяся часть файла содержит строки из набора S. Каждая строка состоит из ASCII символов с кодами от 32 до 126 включительно. Строка может быть пустой и ее длина не превышает 250-ти символов.

Гарантируется, что размер входного файла не превышает 1 Мбайт.

Формат выходных данных

В выходной файл выведите все строки из набора S (в том порядке, в котором они находятся во входном файле), содержащие как подстроку по крайней мере одну строку из набора T.

Пример

console.in	console.out
3	sudislavl
gr	group a'
sud	
abc	
lksh	
sudislavl	
kostroma	
summer	
group a'	

Замечание

Если у вас WA 36, вы неправильно читаете входные данные. Строки могут состоять только из пробелов.

Задача С. К-я строка [0.5 sec, 256 mb]

Реализуйте структуру данных, которая поддерживает следующие операции:

- добавить в словарь строку S;
- найти в словаре *k*-ю строку в лексикографическом порядке.

Изначально словарь пуст.

Формат входных данных

Первая строка входного файла содержит натуральное число N — количество команд $(N \leq 10^5)$. Последующие N строк содержат по одной команде каждая.

Команда записывается либо в виде числа k, либо в виде строки S, которая может состоять только из строчных латинских букв. Гарантируется, что при запросе k-й строки она существует. Также гарантируется, что сумма длин всех добавляемых строк не превышает 10^5 .

Формат выходных данных

Для каждого числового запроса k выходной файл должен содержать k-ю в лексикографическом порядке строчку из словаря на момент запроса. Гарантируется, что суммарная длина строк в выходном файле не превышает 10^5 .

kthstr.in	kthstr.out
7	tolstoy
pushkin	tolstoy gogol
lermontov	
tolstoy	
gogol	
gorkiy	
5	
1	

Задача D. Prof. Жужжащий профессор [0.1 sec, 256 mb]

Эта задача точно зайдёт, если использовать сжатое суффиксное дерево за $\mathcal{O}(n^2)$.

В одном очень известном университете один очень известный профессор очень быстро произносил свои лекции, так, что ничего невозможно было разобрать. Студенты шутили по этому поводу, что он не говорит, а жужжит. Естественно, что про загадочного профессора никто абсолютно ничего не знал.

Но вот недавно Петя Булочкин решил предпринять исследование по изучению словарного запаса профессора. С этой целью он даже посетил одну лекцию и записал все сказанное на ней на диктофон. Затем, прокручивая дома запись с десятикратным замедлением, Петя смог записать все, что сказал профессор. Но вот незадача — профессор говорил так быстро, что, даже прослушивая замедленную запись, нельзя было точно сказать, где он делал паузы между словами. Таким образом, у Пети есть некоторый текст S, состоящий только из маленьких латинских букв — лекция, которая была прочитана профессором.

Петя решил, что те слова, которые профессор употреблял только один раз во время своей лекции, его не интересуют. Кроме того, понятно, что если профессор употреблял некоторое слово два или более раз, то существуют два неперекрывающихся вхождения этого слова в текст S. Назовем непустую строку T кандидатом в слова, если существуют два неперекрывающихся вхождения T в S. Теперь Петя хочет найти все строки, которые являются кандидатами в слова. И поможете ему в этом Вы.

Формат входных данных

Единственная строка входного файла содержит от 1 до $3\,000$ маленьких латинских букв. Это и есть текст S, который прочитал профессор на лекции.

Формат выходных данных

Единственная строка выходного файла должна содержать одно число, равное количеству строк, являющихся кандидатами в слова.

prof.in	prof.out
bbaabbbabb	7

Бонус

Задача Е. Подстроки-3 [0.25 sec, 256 mb]

Даны K строк из маленьких латинских букв. Найдите их наибольшую общую подстроку.

Формат входных данных

В первой строке число K ($1\leqslant K\leqslant 10$). В следующих K строках — собственно K строк (длины строк от 1 до $10\,000$).

Формат выходных данных

Наибольшая общая подстрока.

substr3.in	substr3.out
3	cab
abacaba	
mycabarchive	
acabistrue	

Задача F. Вирусы [0.5 sec, 256 mb]

Комитет По Исследованию Бинарных Вирусов обнаружил, что некоторые последовательности единиц и нулей являются кодами вирусов. Комитет изолировал набор кодов вирусов. Последовательность из единиц и нулей называется безопасной, если никакой ее сегмент (т.е. последовательность из соседних элементов) не является кодом вируса. Сейчас цель комитета состоит в том, чтобы установить, существует ли бесконечная безопасная последовательность из единиц и нулей.

Пример

Для множества кодов {011, 11, 0000} примером бесконечной безопасной последовательности является 010101.... Для множества {01, 11, 00000} бесконечной безопасной последовательности не существует.

Формат входных данных

Первая строка входного файла virus. in содержит одно целое число N, равное количеству всех вирусных кодов. Каждая из следующих n строк содержит непустое слово, составленное из символов 0 и 1 — код вируса. Суммарная длина всех слов не превосходит $30\,000$.

Формат выходных данных

Первая и единственная строка выходного файла должна содержать слово:

- ТАК если бесконечная, безопасная последовательность из нулей и единиц существует;
- NIE в противном случае.

virus.in	virus.out
3	NIE
01	
11	
00000	
3	TAK
011	
11	
0000	

Задача G. Набор строк [3.5 sec, 256 mb]

В Инновационном Отделе НИИ Исследований Данных Строк разработана клавиатура для внутреннего пользования, облегчающая набор строк огромной длины. Кроме обычных клавиш, соответствующих маленьким латинским буквам, на клавиатуре есть еще n функциональных клавиш F_1, \ldots, F_n , соответствующих заданным строкам из словаря $S_1, \ldots S_n$. При нажатии такой клавиши F_i строка S_i загружается во внутреннюю память клавиатуры. В каждый момент времени в памяти может находиться не более одной строки из словаря.

Кроме того, в клавиатуру встроен графический манипулятор «Кыш», с помощью которого легким движением руки можно ввести любую подстроку находящейся в памяти строки.

Вася занимается исследованием эффективности данного нововведения. Для этого ему требуется написать программу, которая будет вычислять минимальное необходимое количество действий (нажатий и использований «Кыш») для ввода данной строки S. В момент начала ввода строки память пуста.

Например, если требуется ввести строку "abacaba", а в словаре есть строки "baba" и "caca", то это можно сделать за четыре действия — нажать F_1 , выбрать манипулятором подстроку "aba", затем нажать 'c', и опять выбрать манипулятором подстроку "aba". Если бы нужно было набрать с таким словарем "bacababa", то это можно сделать за пять действий: 'b', F_2 , "aca", F_1 , "baba".

Формат входных данных

В первой строке входного файла задано число n ($1 \le n \le 50$). В последующих n строках заданы S_i , составленные из не более чем 500 символов. В последней строке вводится непустая строка S, длина которой не превосходит 100 000. Все символы строк — маленькие латинские буквы.

Формат выходных данных

Выведите минимальное необходимое количество действий.

typing.in	typing.out
2	4
baba	
caca	
abacaba	
2	5
baba	
caca	
bacababa	

Задача Н. Под-бор [1 sec, 256 mb]

Бором называется подвешенное дерево, на каждом из рёбер которого написано по символу, причём символы, написанные на рёбрах, выходящих из общей вершины-родителя, различны. Будем называть направление от родителя к детям "вниз". Назовем вхождением строки в в бор такую вершину бора, от которой можно пройти несколько шагов вниз таким образом, что встретившиеся символы образуют строку s.

Даны бор и несколько строк, найдите сумму количеств вхождений этих строк в этот бор.

Формат входных данных

В первой строке входного файла записано единственное число $n, 1 \leq n \leq 100\,000$ — количество вершин бора. В следующих n строках описаны вершины бора. В (i+1)-й строке описаны дети i-й вершины: число k_i ее детей, затем k_i пар из номера вершины-ребёнка и символа, написанного на соответствующем ребре. Номер родителя всегда меньше номера ребёнка; корнем бора является вершина номер 1.

В (n+2)-й строке записано количество m ($1 \le m \le 100\,000$) строк для поиска. В следующих m строках перечислены сами строки. Входные строки непусты, а их суммарная длина не превышает $100\,000$ символов.

Все символы, написанные на рёбрах, а также все символы, составляющие строки — маленькие латинские буквы.

Формат выходных данных

Выведите одно число — сумму количеств вхождений.

trie.in	trie.out
7	9
2 2 a 4 b	
2 3 a 6 b	
0	
1 5 b	
1 7 b	
0	
0	
4	
b	
bb	
bbb	
bb	